Educação Profissional Paulista

Técnico em **Ciência de Dados**

GOVERNO DO ESTADO
DE SÃO PAULO

Modelos, algoritmos e estimadores

Regressão logística (parte 1)

Introdução à regressão logística

Código da aula: [DADOS]ANO2C1B2S8A1

GOVERNO DO ESTADO
DE SÃO PAULO

Mapa da Unidade 2 Componente 1

Modelos, algoritmos e estimadores

semana 8

Você está aqui!
Regressão logística (parte 1)

semana 9

Regressão logística (parte 2)

semana 10

Árvores de decisão (parte 1)

semana 12

Random Forest

Modelos, algoritmos e estimadores

Mapa da Unidade 2 Componente 1

Você está aqui!

8

Regressão logística (parte 1)

Aula 1 – Introdução à regressão logística

Código da aula: [DADOS]ANO2C1B2S8A1

Objetivos da aula

- Compreender o funcionamento da regressão logística.

Recursos didáticos

- Recurso audiovisual para exibição de vídeos e imagens;
- Acesso ao laboratório de informática e/ou à internet;
- Software Anaconda/Jupyter Notebook instalado ou similar.

Duração da aula

50 minutos

Habilidades técnicas

- Implementar algoritmos de regressão logística.

Habilidades socioemocionais

- Demonstrar persistência na resolução de problemas complexos.

Ponto de **partida**

Quem passa e quem não passa

Você quer prever se os alunos de uma escola vão **passar ou não** em uma prova de matemática com base no **número de horas que eles estudam**.

A regressão logística é usada para prever **respostas binárias**, ou seja, coisas que têm apenas dois resultados: **passar ou não passar**.

- Você tem dados de 10 alunos.
- Para cada aluno, você sabe quantas horas ele estudou e se ele passou ou não.

Horas Estudadas	Passou (Sim = 1, Não = 0)
1	0
2	0
3	0
4	1
5	1
6	1
7	1
8	1
9	1
10	1

Produzido pela SEDUC-SP.

- A partir desses dados, se um aluno estudar por 5 horas quais as chances dele passar?
- Será que a chance aumenta se ele estudar 6 horas?

Ponto de
partida

Quem passa e quem não passa

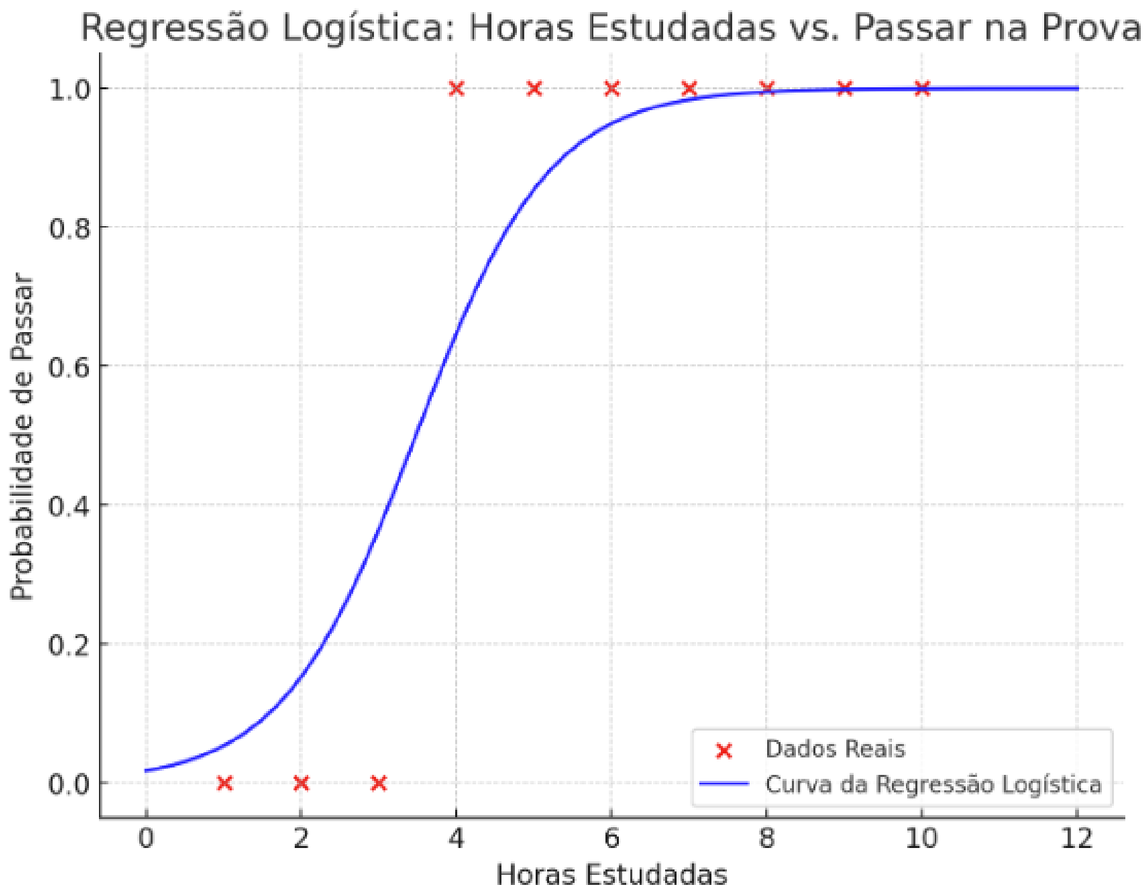

Produzido pela SEDUC-SP com a ferramenta Jupyter Notebook.

Colocando em **prática**

Definição da regressão logística

A **regressão logística** é um modelo de classificação que busca entender a relação entre uma variável independente e uma variável dependente categórica, ou seja, que assume valores como "sim" ou "não", "verdadeiro" ou "falso".

Em vez de traçar uma linha reta, como na regressão linear, a regressão logística usa uma **curva em formato de "S"** (curva **sigmoide**) para representar a relação entre as variáveis.

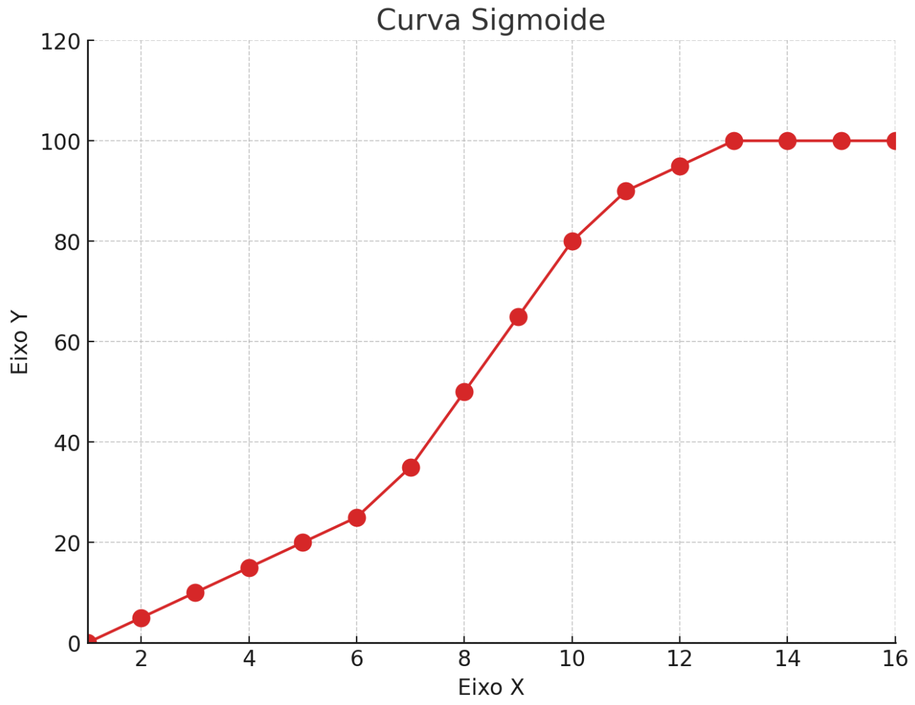

Produzido pela SEDUC-SP com apoio da ferramenta Data Analyst.

Colocando em **prática**

Definição da regressão logística

Essa curva ajuda a prever a probabilidade de um evento acontecer com base nos valores das variáveis independentes.

Enquanto a reta da regressão linear mostra uma relação constante, a curva sigmoide da regressão logística mostra como a chance de algo acontecer aumenta ou diminui com base nos valores da variável independente.

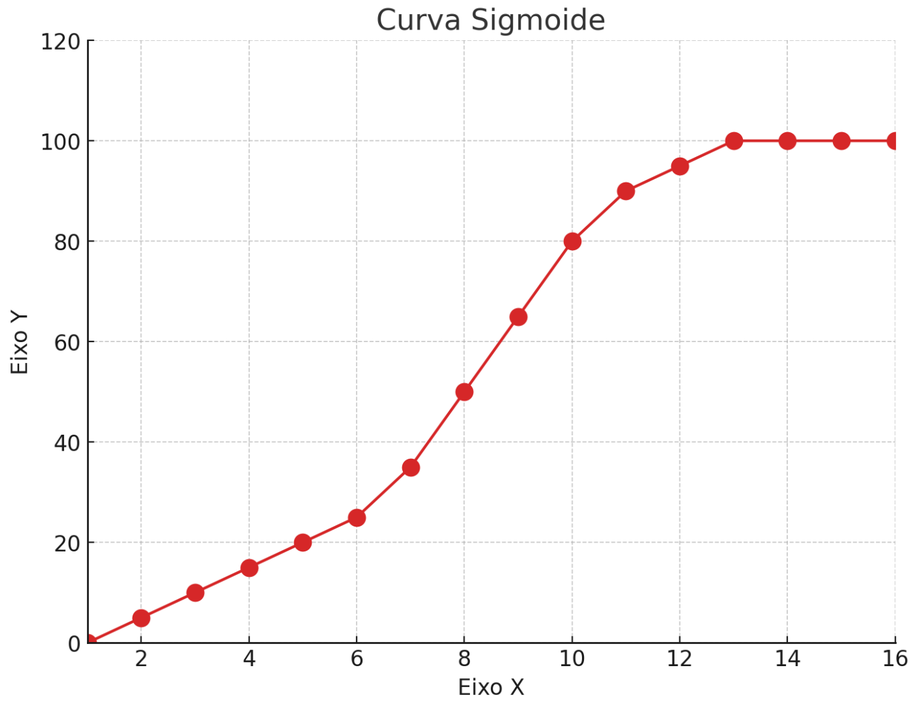

Produzido pela SEDUC-SP com apoio da ferramenta Data Analyst.

Colocando em **prática**

Função sigmoide

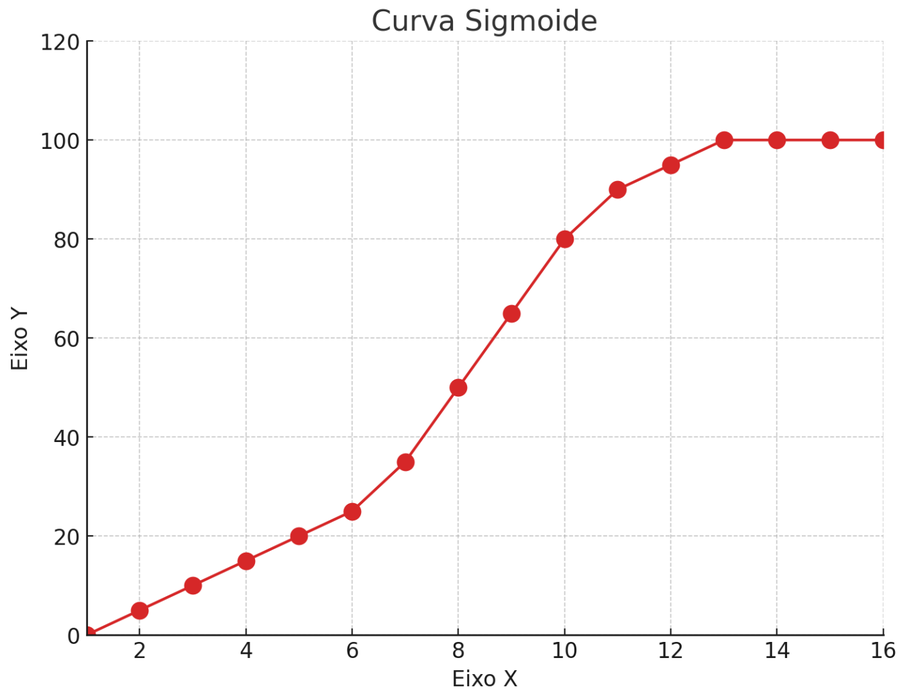

Produzido pela SEDUC-SP com apoio da ferramenta Data Analyst.

A função sigmoide pega qualquer número e o transforma em um valor entre 0 e 1, o que é útil para representar probabilidades.

Se o número for grande, a sigmoide dá um valor próximo de 1; se for pequeno, dá um valor perto de 0.

Colocando em **prática**

Função sigmoide

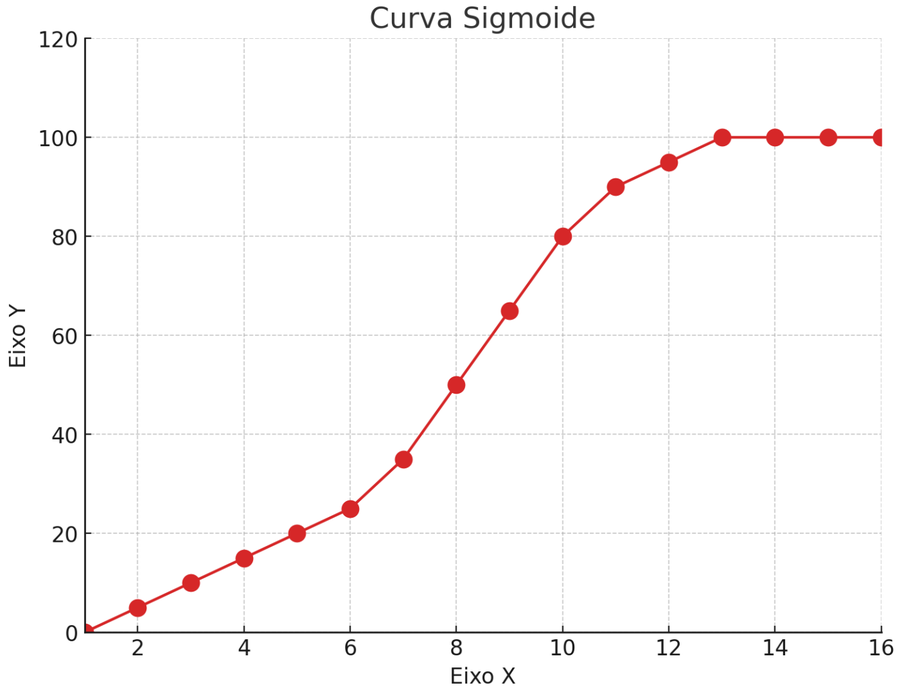

Produzido pela SEDUC-SP com apoio da ferramenta Data Analyst.

Isso ajuda em modelos de machine learning, como a regressão logística, porque em vez de usar números complicados, conseguimos prever algo de forma simples, como se a chance de um aluno passar é alta ou baixa, com base nas suas notas e em outros fatores.

Colocando em **prática**

Por que a função sigmoide é importante para a regressão logística?

A regressão logística utiliza a função sigmoide porque, justamente, ela transforma qualquer valor numérico em uma probabilidade entre 0 e 1.

A função sigmoide é ideal para problemas de classificação binária (como "aprovado" ou "reprovado").

Exemplo: isso nos permite dizer que há **70%** de probabilidade de um aluno ser **aprovado** ou **30%** de probabilidade de **reprovação**, tornando mais fácil tomar decisões baseadas nessas probabilidades.

Colocando em **prática**

Interpretando a regressão logística

No caso de aprovação de alunos, se o modelo leva em conta características como frequência e notas, a saída será a probabilidade de um aluno ser aprovado.

Exemplo: se um aluno estuda por um certo número de horas e o modelo prevê uma probabilidade de 70%, isso significa que esse aluno tem 70% de chance de ser aprovado. Nesse contexto, o valor previsto indica a chance de o aluno ser aprovado ou não.

Colocando em **prática**

Interpretando a regressão logística

Também é possível definir um limite, chamado **limiar**, para classificar se o aluno será aprovado.

Se definirmos um limiar mais alto, como 90%, somente consideraremos alunos com uma probabilidade muito alta de aprovação, o que reduz o risco de erros.

Colocando em **prática**

Quais são os tipos de análise de regressão logística?

1

Binária

Classificação entre duas opções (sim/não).

2

Multinomial

Classificação em mais de duas categorias, sem ordem (maçã, banana, laranja).

3

Ordinal

Classificação em categorias com uma ordem natural (insatisfeito, neutro, satisfeito).

Tome nota

Adicione os conceitos mais importantes à sua folha de dicas e consulte o material de referência do conjunto de dados para informações detalhadas.

Colocando em **prática**

Previsão de aprovação de alunos

Reflexão e discussão em grupo

30 minutos

Grupo (4 alunos)

Materiais necessários

- Recurso audiovisual para exibição de vídeos e imagens;
- Acesso ao laboratório de informática e/ou à internet.

Passo a passo

Em grupo, a partir do caso disponível no roteiro de atividade prática, sigam os passos abaixo:

1. Analisem os padrões nos dados dos alunos 1 a 7;
2. Comparem o Aluno 7 com os demais estudantes indicados na tabela;
3. Prevejam o resultado do Aluno 7.

Baixe o roteiro dessa atividade.

Registro

Pause e
responda

A regressão logística é utilizada para:

- Prever um valor contínuo.
- Modelar a relação entre múltiplas variáveis preditoras e um resultado contínuo.
- Prever múltiplas categorias.
- Prever um resultado binário.

Registro

Pause e **responda**

A regressão logística é utilizada para:

- ✗ Prever um valor contínuo.
- ✗ Modelar a relação entre múltiplas variáveis preditoras e um resultado contínuo.
- ✗ Prever múltiplas categorias.
- ✓ Prever um resultado binário.

© Getty Images

O que nós **aprendemos hoje?**

Então ficamos assim...

1. A regressão logística prevê a probabilidade de um evento binário, como passar ou não, usando variáveis independentes. Com uma única variável, usamos a regressão logística simples;

2. Essa técnica não prevê valores contínuos, mas sim a probabilidade de um evento ocorrer ou não;

3. A regressão logística usa a curva sigmoide (tem formato de "S“) para representar a relação entre as variáveis.

Saiba mais

Descubra como a regressão logística pode transformar a análise de dados! Acesse o link abaixo e entenda esse poderoso método estatístico para modelar probabilidades e prever resultados.

AMAZON WEB SERVICES (AWS). O que é regressão logística? [s.d.]. Disponível em: https://aws.amazon.com/pt/what-is/logistic-regression/. Acesso em: 22 nov. 2024.

Referências da aula

Identidade visual: imagens © Getty Images

GÉRON, A. **Mãos à obra**: aprendizado de máquina com Scikit-Learn, Keras e TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. Rio de Janeiro: Alta Books, 2021.

GRUS, J. **Data Science do zero**: noções fundamentais com Python. Rio de Janeiro: Alta Books, 2021.

Orientações ao professor

Slides 6 e 7

Orientações: Professor, a **seção Ponto de partida** aparece no início de cada aula e tem como objetivos ativar o conhecimento prévio dos estudantes sobre o tema da aula e estimular seu pensamento crítico e suas habilidades comunicativas. Por meio de uma situação-problema ou exemplo próximo da realidade do estudante, pretende-se sair da abstração conceitual e promover um diálogo dinâmico para explorar hipóteses, soluções e compartilhar eventuais experiências que os estudantes já possam ter com os tópicos a serem abordados na aula. Também é um momento de engajá-los em relação ao tema da aula.

Tempo previsto: 8 minutos

Gestão de sala de aula: assegure que todos os estudantes tenham a oportunidade de participar. Se necessário, faça rodízio ou direcione perguntas a estudantes que estejam menos ativos para garantir a participação de todos.
Mantenha um ambiente de respeito em que todas as opiniões são valorizadas, garantindo que todos se sintam confortáveis para expressar seus pontos de vista.
Conclua a atividade resumindo as principais ideias discutidas e vinculando-as aos objetivos de aprendizagem da aula.

Condução da dinâmica: leia com os alunos a tabela e questione a chance de um aluno passar estudando 5 horas.
Conduza a discussão dizendo que a regressão logística ajuda a encontrar uma relação entre o número de horas estudadas e a probabilidade de passar, gerando uma curva que se parece com um "S". Essa curva mostra que à medida que as horas de estudo aumentam, a **chance de passar** também aumenta.
Então, se você perguntar: "Se alguém estudar por 5 horas, quais são as chances de passar?", a **regressão logística** te dá uma **resposta!**

Expectativas de respostas:

Compreensão Intuitiva: muitos alunos podem entender que, conforme estudam mais horas, a probabilidade de sucesso aumenta, o que faz sentido para eles. A curva em forma de "S" ajuda a visualizar que o aumento nas horas de estudo tem um impacto direto no desempenho.
Perguntas sobre a "certeza": alguns alunos podem perguntar por que, mesmo estudando bastante, ainda não há 100% de certeza de passar. Isso pode levar a uma conversa sobre variabilidade e que, em muitos casos, o desempenho também depende de outros fatores, além das horas estudadas.
Curiosidade sobre o gráfico: eles podem perguntar como a curva foi criada e por que não é uma linha reta. Isso é uma boa oportunidade para mencionar que a regressão logística lida com probabilidades (que variam entre 0 e 1) e não pode ser linear porque, no mundo real, não é garantido que mais horas sempre levem a 100% de sucesso.
Engajamento com a matemática: se o exemplo for claro e acessível, isso pode despertar o interesse deles em explorar como outras variáveis afetam as chances de sucesso, aplicando a ideia em outros contextos (como esportes ou hábitos).
Alguma confusão inicial: alguns alunos podem achar a ideia de "probabilidade" abstrata e precisar de mais exemplos ou uma explicação mais visual, como se aproximando da ideia de "quanto mais estudo, maior a chance", sem que isso seja uma garantia.

Continua

Slides 6 e 7

Expectativas de respostas:

Código do gráfico

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LogisticRegression

# Dados
horas_estudadas = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10]).reshape(-1, 1)
resultado = np.array([0, 0, 0, 1, 1, 1, 1, 1, 1, 1])

# Criar e treinar o modelo de regressão logística
modelo = LogisticRegression()
modelo.fit(horas_estudadas, resultado)

# Gerar predições para uma gama de valores de horas
horas_novas = np.linspace(0, 12, 300).reshape(-1, 1)
probabilidades = modelo.predict_proba(horas_novas)[:, 1]

# Criar gráfico
plt.figure(figsize=(8, 6))
plt.scatter(horas_estudadas, resultado, color='red', label='Dados Reais')
plt.plot(horas_novas, probabilidades, color='blue', label='Curva da Regressão Logística')
plt.xlabel('Horas Estudadas')
plt.ylabel('Probabilidade de Passar')
plt.title('Regressão Logística: Horas Estudadas vs. Passar na Prova')
plt.legend()
plt.grid(True)
plt.show()
```

Slides 8 e 9

Orientações: Professor, a **seção Colocando em prática** tem como objetivo aplicar os conhecimentos construídos durante a aula incentivando os estudantes a pensarem criticamente e de forma prática.

Tempo previsto: 36 minutos (ao todo)

Gestão de sala de aula:
Organização do espaço: divida os alunos em grupos. Cada grupo trabalha em uma estação (computador). Nomeie cada estação de trabalho com um número ou letra para fácil referência.
Estação de revisão: designar uma "Estação de Revisão" (pode ser um quadro branco ou um espaço onde você, como professor, fica disponível). Alunos que terminam a tarefa mais cedo ou que precisam de ajuda devem vir à Estação de Revisão para apresentar seu progresso ou discutir dificuldades.
Autonomia e colaboração: incentive os alunos a tentar resolver problemas primeiro entre seus pares antes de pedir ajuda. Isso fortalece a colaboração e a capacidade de resolução de problemas. Alunos que resolvem um problema de forma eficiente podem ser incentivados a ajudar outros grupos.
Rotina de verificação: realize verificações periódicas, caminhando pelo laboratório para observar o progresso dos grupos, oferecendo dicas ou ajustando o foco, se necessário.
Revisão e reflexão: no final da sessão, reserve alguns minutos para uma revisão em grupo. Peça a alguns grupos para compartilharem soluções ou discutirem desafios enfrentados. Use essa oportunidade para reforçar boas práticas de programação, comportamento em laboratório e revisão de conceitos. Oriente os alunos a criar uma folha com os assuntos/fórmulas/códigos mais importantes da aula (peça para preencherem aula a aula).

Condução da dinâmica:
Passo 1: apresente o conceito principal de forma concisa, usando linguagem e exemplos simples e relevantes. Permita algumas perguntas rápidas para garantir a compreensão antes de seguir adiante (15 minutos).
Passo 2: leia a tarefa e oriente os grupos a começarem a atividade. Nessa atividade, os alunos irão discutir a solução e não será usado o notebook nessa aula (16 minutos).
Finalize e aula com a discussão do resultado (5 minutos).

Expectativas de respostas:
Analisando os dados, podemos observar uma tendência clara:
- Alunos que estudaram menos de 8 horas por semana (Alunos 1 e 2) não passaram de ano;
- Alunos que estudaram mais de 8 horas por semana (Alunos 3, 4, 5, e 6) e fizeram simulados tiveram sucesso;
- Além disso, todos os alunos que tiveram aulas de reforço e fizeram mais de 1 simulado passaram.

O Aluno 7 estudou 10 horas por semana, fez 1 simulado e participou de aulas de reforço. Comparando-o com o Aluno 3, que também estudou cerca de 8 horas, fez 1 simulado e teve aulas de reforço, parece provável que o Aluno 7 também passe de ano.

Previsão: com base nos padrões, é provável que o Aluno 7 passe de ano. Portanto, a previsão seria **1** (passou de ano).

Slide 17

Seção Pause e responda

Tempo: 3 minutos

Pergunta: A regressão logística é utilizada para:

Resposta correta: Prever um resultado binário.

Feedback: a regressão logística simples é usada para prever um resultado binário (como passar ou não em uma prova) utilizando uma única variável independente, como o número de horas de estudo.

Slide 19

Orientações: Professor, **a seção O que nós aprendemos hoje?** tem o objetivo de reforçar e esclarecer os conceitos principais discutidos na aula. Essa revisão pode ser uma ferramenta de avaliação informal do aprendizado dos estudantes, identificando áreas que possam precisar de mais atenção em aulas futuras.

Tempo previsto: 2 minutos

Gestão de sala de aula:
Mantenha um tom positivo e construtivo, reforçando o aprendizado em vez de focar em correções.
Seja direto e objetivo nas explicações para manter a atividade dentro do tempo estipulado.
Engaje os estudantes rapidamente, pedindo confirmações ou reações breves às definições apresentadas.

Condução da dinâmica:
Explique que esta parte da seção, "Então ficamos assim...", é um momento de reflexão e esclarecimento sobre os conceitos abordados na aula.
Informe que será uma rápida revisão para assegurar que os entendimentos dos estudantes estão alinhados com as definições corretas dos conceitos.
Apresente o slide com a definição sintética de cada conceito principal discutido na aula, ampliando em forma de frases completas.
Finalize resumindo os pontos principais e reiterando a importância de cada conceito e como ele se encaixa no contexto maior da aula.
Reforce a ideia de que essa revisão ajuda a solidificar o entendimento dos estudantes e prepará-los para aplicar esses conceitos em situações práticas.

Expectativas de respostas:
Os estudantes devem sair da aula com um entendimento claro e preciso dos conceitos principais.
A atividade serve como uma verificação rápida do entendimento dos estudantes e uma oportunidade para corrigir quaisquer mal-entendidos.

Educação Profissional Paulista

Técnico em **Ciência de Dados**

GOVERNO DO ESTADO
DE SÃO PAULO